

Construction et Validation d'un Système Hybride de
Notation de Crédit
Chapitres 3 à 7

Khaoula Elhonnya

Année universitaire 2025 – 2026

Table des matières

3	Méthodologie de constitution des données	2
3.1	Sources de données	2
3.2	Fusion et harmonisation des variables	2
3.3	Anonymisation et sécurisation des données	3
3.4	Construction de la base de données	3
3.5	Synthèse	4
4	Construction du système de scoring expert	5
4.1	Principe de la grille	5
4.2	Ratios retenus et pondération	5
4.3	Résultats	6
4.4	Synthèse	7
5	Construction du système de scoring par apprentissage automatique	8
5.1	Construction de la variable cible	8
5.2	Variables explicatives et protocole d'évaluation	9
5.3	Résultats	9
5.4	Importance des variables	10
5.5	Synthèse	11
6	Système de décision hybride et confrontation à la notation réelle	12
6.1	D'un score à une décision	12
6.2	Score hybride pour la notation A-E	12
6.3	Moteur de décision logique	13
6.4	Résultats du système de décision	14
6.5	Workflow applicatif et traçabilité	14
6.6	Synthèse	14
7	Discussion, limites et recommandations	16
7.1	Synthèse des résultats	16
7.2	Limites méthodologiques	16
7.3	Recommandations pour une industrialisation	17
7.4	Conclusion générale	17

Chapitre 3

Méthodologie de constitution des données

3.1 Sources de données

Contrairement au périmètre initialement envisagé (données simulées calibrées sur documents de référence), ce travail s'appuie in fine sur **neuf dossiers de crédit réels**, extraits manuellement des captures d'écran de l'outil interne de notation MNS2 du Centre d'Affaires Al Istiqlal. Ces dossiers couvrent trois segments de crédit distincts :

- **Crédit de Fonctionnement / Court Terme (CT)** : 4 dossiers (Feuil2, Feuil3, Feuil8, Feuil5) ;
- **Promotion Immobilière (PI)** : 3 dossiers (Feuil1, Feuil13, Feuil4) ;
- **Moyen/Long Terme (MLT)** : 2 dossiers dont le segment reste à confirmer (Feuil11, Feuil12).

! Taille de l'échantillon

Neuf dossiers constituent un échantillon extrêmement restreint au regard des standards de la modélisation statistique. Ce choix n'est pas une préférence méthodologique mais une contrainte opérationnelle : ces dossiers représentent l'ensemble des cas traités et documentés durant la période de stage. Toutes les analyses qui suivent doivent être lues à la lumière de cette contrainte, explicitée dès le Chapitre 1.

3.2 Fusion et harmonisation des variables

Chaque dossier ayant été saisi indépendamment à partir de captures d'écran, la première étape a consisté à fusionner les neuf tableurs sources en une base unique. Cette fusion brute a fait apparaître **638 colonnes de variables**, un nombre très supérieur au nombre de variables réellement distinctes, en raison de :

1. **Variantes orthographiques** du même intitulé de variable (ex. fautes de frappe lors de la saisie manuelle) ;
2. **Doublons structurels** : certaines variables apparaissent plusieurs fois sous des suffixes `__dup2`, `__dup3`, vraisemblablement liés à des exercices comptables différents (N-2, N-1, N) mal étiquetés à la source ;

3. **Confusions actif/passif** : trois groupes de variables mêlaient des postes d'actif et de passif sous un intitulé commun (ex. `tresorerie_actif` et `tresorerie_passif`), nécessitant une séparation manuelle stricte pour ne pas fusionner des grandeurs comptables non comparables.

Un dictionnaire de correspondance (`variable brute` $\rightarrow$ `variable canonique`) a été construit et appliqué par coalescence : pour chaque dossier et chaque groupe de variables équivalentes, la première valeur non nulle rencontrée est retenue. Cette opération réduit la base de **638 à 339 variables canoniques**, tout en conservant une traçabilité complète du mapping appliqué (table `mapping_nettoyage` de la base de données, cf. Section 3.4).

! Limite méthodologique

La coalescence par « première valeur non nulle » constitue une hypothèse simplificatrice. Si les colonnes `__dup2`/`__dup3` correspondent effectivement à des exercices comptables différents plutôt qu'à des doublons de saisie, cette opération entraîne une perte d'information (seul un exercice est conservé par variable). Ce point est identifié comme prioritaire pour validation avec le maître de stage.

Une correction d'échelle a par ailleurs été appliquée sur la variable `cash_flow` : un dossier présentait une valeur exprimée en dirhams (DH) alors que les autres étaient en milliers de dirhams (KDH), introduisant un facteur d'échelle de 1000 corrigé après détection automatique des incohérences d'unité.

Après nettoyage, la couverture des variables reste très hétérogène : sur les 339 variables canoniques, seules 55 sont renseignées pour au moins 6 des 9 dossiers. Cette forte sparsité a directement orienté le choix du schéma de base de données (Section 3.4) et la sélection des variables retenues pour la modélisation (Chapitre 5).

3.3 Anonymisation et sécurisation des données

Une exigence de sécurité et de confidentialité a été posée dès la conception du système : **aucune donnée identifiante (raison sociale) ne doit transiter par le moteur de scoring, le moteur de décision, ni les modules d'explicabilité**. Concrètement :

- les raisons sociales sont isolées dans une table dédiée (`identites`), distincte de la table des dossiers (`dossiers`), reliées uniquement par un identifiant technique anonyme (`dossier_id`) ;
- les modules de scoring, de machine learning et de feature importance (Chapitres 4 et 5) ne référencent *jamais* la table `identites` ;
- dans l'application (Chapitre 6), seule la vue « Direction » — habilitée à statuer sur le dossier — effectue la jointure permettant de lever l'anonymat.

Cette séparation répond à un principe de *minimisation des données* : chaque composant du système n'accède qu'aux informations strictement nécessaires à sa fonction.

3.4 Construction de la base de données

La base de données finale (SQLite, embarquée, sans dépendance réseau) est structurée autour de sept tables principales, résumées au Tableau 3.1.

Le choix d'un modèle **entité-attribut-valeur (EAV)** pour la table `variables_valeurs` — plutôt qu'une table large de 339 colonnes — est directement motivé par la sparsité

Table	Rôle
dossiers	Une ligne par dossier (identifiant, segment) — anonyme
identites	Correspondance dossier_id → raison sociale — isolée
variables_dictionnaire	Catalogue des 339 variables canoniques (couverture, type)
variables_valeurs	Valeurs au format <i>entité-attribut-valeur</i> (EAV)
mapping_nettoyage	Traçabilité variable brute → variable canonique
notations	Notation MNS2 réelle reconstituée par dossier
scores_calculés / decision_ml	Sorties des systèmes de scoring et de décision (Ch. 4-6)

TABLE 3.1 – Schéma simplifié de la base de données

constatée en Section 3.2 : une table large contiendrait, pour la majorité des variables, plus de 30 % de cellules vides, ce qui est inefficace en stockage et rend les requêtes d'agrégation plus complexes. Le format EAV ne stocke que les couples (dossier, variable, valeur) effectivement renseignés.

3.5 Synthèse

Cette phase de constitution des données, bien qu'en amont du cœur méthodologique du projet (scoring et décision), a représenté une part substantielle du travail réalisé : elle conditionne directement la fiabilité de toutes les analyses ultérieures. Les Chapitres 4 et 5 s'appuient sur cette base nettoyée et anonymisée pour construire, respectivement, le score expert et le score par apprentissage automatique.

Chapitre 4

Construction du système de scoring expert

4.1 Principe de la grille

Le score expert vise à formaliser, sous forme d'une grille pondérée, un jugement de type « analyste de crédit » à partir de ratios financiers directement calculables sur les variables canoniques disponibles (Chapitre 3). Pour chaque ratio retenu, une valeur normalisée sur $[0, 100]$ est calculée selon deux bornes de saturation (plancher/plafond) et un sens d'interprétation (« plus est mieux » ou « moins est mieux »), puis agrégée par une moyenne pondérée.

Définition 4.1.1 (Score expert)

Soit $R = \{r_1, \dots, r_k\}$ l'ensemble des ratios financiers retenus, w_i le poids associé à r_i , et $s_i \in [0, 100]$ le score normalisé du ratio r_i pour un dossier donné. Le score expert est défini par :

$$S_{\text{expert}} = \frac{\sum_{i: r_i \text{ disponible}} w_i \cdot s_i}{\sum_{i: r_i \text{ disponible}} w_i}$$

Le score n'est calculé que sur les ratios effectivement disponibles pour le dossier (pondération renormalisée), ce qui permet de traiter les dossiers incomplets sans imputation arbitraire.

4.2 Ratios retenus et pondération

Six ratios ont été retenus (Tableau 4.1), couvrant les dimensions de rentabilité, de solvabilité et de liquidité — trois piliers classiques de l'analyse financière du risque de crédit (cf. cadre théorique, Chapitre 2).

Ratio	Poids	Sens	Bornes
Rentabilité financière	20 %	plus = mieux	$[-20, 40]$
Autonomie financière	20 %	plus = mieux	$[0, 100]$
Endettement à court terme	15 %	moins = mieux	$[0, 100]$
Liquidité réduite	15 %	plus = mieux	$[0, 200]$
Capacité de remboursement	15 %	plus = mieux	$[0, 10]$
Dettes nettes / fonds propres	15 %	moins = mieux	$[0, 5]$

TABLE 4.1 – Pondération de la grille experte (hypothèse de travail)**! Pondérations non calibrées**

Ces pondérations constituent une *hypothèse de travail initiale*, construite par analogie avec les grilles de scoring classiques documentées dans la littérature (Chapitre 2), et non une reproduction de la grille interne réelle de la Banque Populaire, qui n'est pas documentée dans le périmètre accessible pour ce stage. Une calibration avec le maître de stage — par exemple par ajustement des poids jusqu'à minimiser l'écart avec la notation MNS2 réelle sur les dossiers disponibles — constitue une piste d'amélioration immédiate (cf. Chapitre 7).

4.3 Résultats

Le Tableau 4.2 présente le score expert calculé pour les neuf dossiers de l'échantillon.

Dossier	Score expert / 100
Feuil13	100.0
Feuil2	76.4
Feuil5	60.5
Feuil8	53.8
Feuil12	51.5
Feuil1	44.2
Feuil11	42.3
Feuil3	39.2
Feuil4	N/A (données insuffisantes)

TABLE 4.2 – Score expert par dossier

Le score de 100/100 obtenu par Feuil13 mérite un commentaire : il résulte du fait que ce dossier ne dispose que d'un très petit nombre de ratios renseignés parmi les six retenus, et que ceux-ci sont favorables. Ce cas illustre concrètement une limite du mécanisme de renormalisation évoqué en Section 4.1 : un score calculé sur peu de ratios disponibles est statistiquement moins fiable qu'un score calculé sur l'ensemble de la grille, sans que cela soit visible dans le chiffre final.

! Limite méthodologique

Le score expert ne porte, à ce stade, aucune indication de *confiance* liée au nombre de ratios effectivement disponibles. Une évolution naturelle consisterait à afficher, à côté du score, le nombre de ratios mobilisés (ex. « 51,5/100, calculé sur 4/6 ratios »).

4.4 Synthèse

Le score expert fournit une base transparente et immédiatement justifiable, conforme aux exigences opérationnelles identifiées au Chapitre 2 (Section 2.2). Le Chapitre 5 construit, à partir des mêmes données, un score par apprentissage automatique, avant que le Chapitre 6 ne confronte les deux approches à la notation bancaire réelle.

Chapitre 5

Construction du système de scoring par apprentissage automatique

5.1 Construction de la variable cible

Les données disponibles ne comportent pas d'historique réel d'incidents de paiement permettant de définir directement une variable de défaut. Face à cette contrainte, deux options ont été envisagées : (i) fixer un seuil arbitraire sur le score MNS2 réel (`score_final`), ou (ii) laisser les données elles-mêmes déterminer la coupure séparant les dossiers « sains » des dossiers « à risque ».

La première option a été testée et écartée : sur l'échantillon réel disponible, `score_final` varie entre 53 et 78. Un seuil fixé a priori à 40 (valeur usuelle dans la littérature bancaire pour des scores sur 100) ne produit *aucun* dossier en défaut, rendant tout apprentissage supervisé impossible (variance nulle de la cible).

Définition 5.1.1 (Seuil de défaut dynamique)

Le seuil de défaut est recalculé automatiquement à chaque exécution du pipeline par un algorithme de partitionnement non supervisé (K-means, $k = 2$) appliqué à la distribution des valeurs de `score_final` disponibles. Soit $c_1 < c_2$ les deux centres de cluster obtenus ; le seuil retenu est le point médian $\tau = (c_1 + c_2)/2$. Un dossier est étiqueté « en défaut » si son score est strictement inférieur à τ .

Sur l'échantillon actuel (7 dossiers avec `score_final` renseigné), cette procédure aboutit à $\tau \approx 65,6$, séparant l'échantillon en deux groupes de taille comparable (Tableau 5.3).

! Cible proxy, non un défaut réel

La variable cible ainsi construite est un *proxy statistique* — une coupure relative dans la distribution des scores disponibles — et non un historique réel de défaut de paiement. Son interprétation doit rester prudente : elle indique quels dossiers se distinguent *relativement* aux autres dossiers de l'échantillon, non une probabilité de défaut au sens strict (Bâlois, cf. Chapitre 2, Section 2.1). Ce point devra être discuté explicitement lors de la soutenance et, si possible, validé ou remplacé par un historique réel avec le maître de stage.

L'avantage de cette approche dynamique, par rapport à un seuil fixe, est qu'elle reste valide à mesure que de nouveaux dossiers seront intégrés via le workflow applicatif (Cha-

pitre 6) : le seuil se recalcule alors automatiquement sur la distribution actualisée, sans intervention manuelle.

5.2 Variables explicatives et protocole d'évaluation

Sur les 339 variables canoniques (Chapitre 3), 34 ont été retenues comme candidates explicatives sur la base de leur couverture (présentes pour la majorité des dossiers) et de leur pertinence financière (postes de bilan, de résultat, ratios de structure). Les valeurs manquantes sont imputées par la médiane calculée sur l'échantillon d'entraînement (jamais sur l'échantillon de test, pour éviter toute fuite d'information), et les variables sont standardisées.

Définition 5.2.1 (Validation croisée Leave-One-Out (LOOCV))

Pour un échantillon de n observations, la validation croisée *leave-one-out* consiste à entraîner le modèle n fois, chaque itération excluant une observation différente de l'ensemble d'entraînement pour l'utiliser comme unique observation de test. C'est le seul protocole de validation qui exploite la totalité de l'échantillon disponible tout en garantissant qu'aucune observation testée n'a participé à l'entraînement du modèle qui la prédit — propriété indispensable lorsque n est trop restreint pour un découpage classique entraînement/validation/test.

Deux modèles sont entraînés en parallèle sur les 7 dossiers labellisés : une **forêt aléatoire** (300 arbres, profondeur maximale 4, pondération des classes équilibrée) et une **régression logistique** — cette dernière servant de modèle de référence pour mesurer l'apport réel du changement de paradigme algorithmique (cf. justification théorique, Chapitre 2, Section 2.2).

5.3 Résultats

Le Tableau 5.1 présente, pour chaque dossier labellisé, la probabilité de défaut estimée par chacun des deux modèles en LOOCV.

Dossier	P(défaut) — RF	P(défaut) — LogReg	Label réel
Feuil8	79.3 %	98.6 %	Sain
Feuil11	75.0 %	96.6 %	Sain
Feuil13	60.3 %	83.0 %	Défaut
Feuil2	43.0 %	61.1 %	Défaut
Feuil5	49.7 %	37.0 %	Défaut
Feuil1	40.3 %	42.7 %	Défaut
Feuil3	71.0 %	11.1 %	Sain

TABLE 5.1 – Probabilités de défaut estimées en LOOCV ($n=7$)

Plusieurs observations se dégagent. D'abord, les deux modèles se trompent nettement sur Feuil8 et Feuil11 (labellisés sains mais prédits en défaut avec forte confiance), et divergent fortement entre eux sur Feuil3 (71 % pour la forêt aléatoire contre 11 % pour

la régression logistique). Ce désaccord inter-modèles, combiné à des erreurs de classification sur un échantillon aussi restreint, doit être interprété comme un signal de **sur-apprentissage** plausible plutôt que comme une réelle difficulté de prédiction : avec 6 observations d'entraînement à chaque itération LOOCV, la capacité de généralisation des deux modèles est structurellement limitée.

! Performance non généralisable

Avec $n = 7$ dossiers labellisés, les métriques de performance (taux de bonne classification, AUC) calculées sur ce LOOCV ne doivent en aucun cas être présentées comme une estimation fiable de la performance du système sur de nouveaux dossiers. Elles sont rapportées à titre indicatif, pour comparer les deux modèles entre eux sur cet échantillon précis, conformément au cadre posé au Chapitre 2 (Section 2.3).

5.4 Importance des variables

Le Tableau 5.2 présente les dix variables les plus déterminantes selon la diminution moyenne d'impureté (MDI) du modèle de forêt aléatoire entraîné sur l'ensemble de l'échantillon labellisé.

Variable	Importance (MDI)
Matériel et agencement	0.076
Banque, caisse, CCP	0.070
Financement permanent	0.066
Rentabilité globale	0.049
Capacité de remboursement	0.048
Actif immobilisé net	0.048
Capital social personnel	0.044
Trésorerie nette	0.043
Consommation de l'exercice	0.040
Réserves	0.038

TABLE 5.2 – Facteurs les plus déterminants (importance MDI, Random Forest)

La prédominance de variables liées à la **structure de l'actif immobilisé** (matériel et agencement, actif immobilisé net) et à la **liquidité immédiate** (banque/caisse/CCP, trésorerie nette) est cohérente avec l'intuition financière : ce sont des indicateurs directs de la capacité de l'entreprise à honorer ses engagements à court terme. La présence du *financement permanent* en troisième position souligne également le rôle de la structure de financement à long terme dans la discrimination des dossiers.

! Importance par permutation non informative

L'importance par permutation, calculée en complément de l'importance MDI, retourne des valeurs quasi nulles pour l'ensemble des variables sur cet échantillon. Ce résultat s'explique par la taille de l'échantillon labellisé (7 observations) : la permutation d'une variable sur un jeu de test aussi restreint ne modifie pas suffisamment la performance mesurée pour être détectée de façon fiable. Seule l'importance MDI est donc interprétée dans ce chapitre.

5.5 Synthèse

Le système de scoring par apprentissage automatique met en évidence des facteurs financiers cohérents avec la théorie du risque de crédit, mais ses prédictions individuelles doivent être interprétées avec une grande prudence compte tenu de la taille de l'échantillon. Le Chapitre 6 combine ce score avec le score expert (Chapitre 4) au sein d'un moteur de décision unique, et confronte les résultats obtenus à la notation MNS2 réelle.

Chapitre 6

Système de décision hybride et confrontation à la notation réelle

6.1 D'un score à une décision

Les Chapitres 4 et 5 ont produit deux *scores* — une grandeur continue à interpréter. Or l'objectif opérationnel posé pour ce projet (Chapitre 1) est différent : produire un **système de décision**, c'est-à-dire une sortie discrète et actionnable (accepté / refusé / à étudier), assortie d'une justification explicite. Cette distinction reprend la terminologie usuelle en aide à la décision : la banque dispose aujourd'hui d'un système d'*aide* à la décision (un score que l'analyste doit interpréter) ; ce projet propose un système de *décision* au sens où il rend un verdict directement exploitable, tout en conservant une zone d'arbitrage humain explicite pour les cas ambigus.

6.2 Score hybride pour la notation A-E

Un premier score hybride, destiné à reconstruire la notation-lettre MNS2 (A à E), combine les trois sorties disponibles par une moyenne pondérée :

$$S_{\text{hybride}} = 0,30 \cdot S_{\text{expert}} + 0,35 \cdot S_{\text{RF}} + 0,35 \cdot S_{\text{LogReg}}$$

où S_{RF} et S_{LogReg} sont des scores sur 100 dérivés des probabilités de classe prédites par les deux modèles (Chapitre 5, adaptés ici à la prédiction multi-classe A-E). Le Tableau 6.1 confronte, pour chaque dossier, la notation-lettre réelle à la notation prédite par le système hybride.

Un seul dossier — **Feuil2** — présente un écart de deux crans ou plus (E réel contre C prédit), et est à ce titre flaggé automatiquement par le système comme divergence à investiguer. Les autres dossiers présentent des écarts d'au plus un cran, ce qui, compte tenu de la taille de l'échantillon, ne permet pas de conclure formellement à une bonne performance du système mais constitue un signal encourageant sur la cohérence d'ensemble entre logique experte, apprentissage statistique et notation bancaire réelle.

Dossier	MNS2 réel	Score hybride /100	Notation prédite	Divergence
Feuil2	E	52.9	C	Oui
Feuil1	D	51.5	C	Non
Feuil11	B	50.1	C	Non
Feuil13	D	53.8	C	Non
Feuil3	C	50.7	C	Non
Feuil12	C	44.6	D	Non
Feuil4	D	42.9	D	Non
Feuil5	D	47.2	D	Non
Feuil8	E	42.8	D	Non

TABLE 6.1 – Confrontation notation MNS2 réelle vs. notation prédite (score hybride)

! Cas Feuil2 à investiguer

Le dossier Feuil2 présente une notation MNS2 réelle très défavorable (E) alors que le score expert (76,4/100, cf. Tableau 4.2) et le système hybride (52,9/100, notation C) le classent de façon nettement plus favorable. Trois explications sont possibles : (i) un facteur qualitatif non capturé par les variables quantitatives disponibles a pesé fortement dans la décision bancaire réelle ; (ii) une erreur de segment ou de saisie affecte ce dossier ; (iii) la pondération de la grille experte (Chapitre 4) est mal calibrée pour ce profil de dossier. Ce cas est identifié comme prioritaire pour une investigation qualitative avec le maître de stage.

6.3 Moteur de décision logique

Pour la détection de défaut (Chapitre 5), le moteur de décision applique une règle explicite, combinant la probabilité de défaut hybride et le score expert comme garde-fou :

Définition 6.3.1 (Règle de décision)

Soit $p = \frac{p_{\text{RF}} + p_{\text{LogReg}}}{2}$ la probabilité de défaut hybride (moyenne des deux modèles lorsque les deux sont disponibles). La décision du système est :

$$\text{Décision} = \begin{cases} \text{REFUSÉ} & \text{si } p \geq 0,60 \\ \text{ACCEPTÉ} & \text{si } p \leq 0,25 \text{ et } S_{\text{expert}} \geq 30 \\ \text{À ÉTUDIER} & \text{sinon} \end{cases}$$

Le garde-fou sur S_{expert} empêche une acceptation automatique lorsque le score expert est très défavorable malgré un avis favorable du modèle statistique — une divergence entre les deux approches (Chapitre 2, Section 2.5) est alors traitée comme un signal d'alerte à soumettre à l'arbitrage humain plutôt que comme un cas tranché.

Les seuils (60 % / 25 %) sont, comme les pondérations de la grille experte, des **hypothèses de travail** à ajuster avec le maître de stage — par exemple par calibration sur un échantillon de dossiers plus large, une fois le workflow applicatif (Section 6.4) alimenté par de nouveaux cas.

6.4 Résultats du système de décision

Dossier	P(défaut) hybride	Décision	Cohérence avec label
Feuil8	88.9 %	REFUSÉ	Non (label = sain)
Feuil11	85.8 %	REFUSÉ	Non (label = sain)
Feuil13	71.6 %	REFUSÉ	Oui (label = défaut)
Feuil2	52.0 %	À ÉTUDIER	—
Feuil5	43.3 %	À ÉTUDIER	—
Feuil1	41.5 %	À ÉTUDIER	—
Feuil3	41.0 %	À ÉTUDIER	—
Feuil12	N/A	À ÉTUDIER	Données insuffisantes
Feuil4	N/A	À ÉTUDIER	Données insuffisantes

TABLE 6.2 – Décisions rendues par le système

Sur cet échantillon, le système ne rend jamais de décision « ACCEPTÉ » automatique : les probabilités de défaut estimées, même pour les dossiers labellisés sains, restent au-dessus du seuil de 25 %. Ce constat, plutôt qu’une faiblesse du système, illustre une conséquence directe et attendue de la taille de l’échantillon : avec seulement 6 observations d’entraînement à chaque itération LOOCV, les modèles restent prudents et ne produisent pas de probabilités très proches de 0. Le système privilégie ainsi, par construction, l’arbitrage humain (« à étudier ») à la décision automatique dans les cas ambigus — un choix de conception délibéré compte tenu des enjeux d’un refus ou d’un octroi de crédit erroné.

6.5 Workflow applicatif et traçabilité

Le système de décision est intégré à une application (tableau de bord interactif) organisée autour de trois vues :

- **Analyste** : dépôt d’un dossier et rédaction d’un commentaire argumentant en faveur du client (élément qualitatif non capturé par les variables quantitatives) ;
- **Direction** : consultation de la décision automatique et de sa justification, croisée avec l’argumentaire de l’analyste, puis validation ou arbitrage final ; cette étape génère automatiquement un procès-verbal (PV) de décision, horodaté et exportable ;
- **Explicabilité** : vue anonymisée présentant les facteurs déterminants (Chapitre 5, Section 5.4) et l’ensemble des décisions rendues, à des fins d’audit et de pédagogie interne.

Ce workflow répond directement à la problématique de transparence posée au Chapitre 1 : chaque décision est traçable, justifiée, et laisse une place explicite à l’expertise humaine sur les cas ambigus, sans reproduire l’opacité de « boîte noire » identifiée dans la littérature (Chapitre 2, Section 2.4).

6.6 Synthèse

La confrontation du système hybride à la notation MNS2 réelle fait apparaître une cohérence globale satisfaisante (huit dossiers sur neuf sans divergence marquante), tout en identifiant un cas prioritaire d’investigation qualitative (Feuil2). Le moteur de décision transforme ces scores en verdicts actionnables, avec une zone d’arbitrage humain explicite

pour les cas où la confiance du système reste limitée — une conséquence assumée et documentée de la taille de l'échantillon.

Chapitre 7

Discussion, limites et recommandations

7.1 Synthèse des résultats

Ce travail a permis de construire, à partir de neuf dossiers de crédit réels du Centre d’Affaires Al Istiqlal, un système hybride combinant une grille de scoring experte (Chapitre 4), un modèle d’apprentissage automatique évalué en LOOCV (Chapitre 5), et un moteur de décision logique explicite (Chapitre 6). Trois résultats principaux se dégagent :

1. Le système hybride reproduit correctement la notation MNS2 réelle à un cran près pour huit dossiers sur neuf, et isole automatiquement le seul cas de divergence marquée (Feuil2) pour investigation qualitative — validant la capacité du dispositif à *signaler* les cas atypiques plutôt qu’à simplement produire un score ;
2. L’analyse d’importance des variables (Random Forest) fait ressortir des facteurs financiers cohérents avec la théorie du risque de crédit — structure de l’actif immobilisé et liquidité immédiate en tête — apportant un premier niveau d’explicabilité globale au système ;
3. Le moteur de décision, en s’abstenant de trancher automatiquement lorsque la confiance du modèle est insuffisante (zone « à étudier »), traduit concrètement l’articulation entre automatiser et jugement humain qui structure la problématique de ce projet (Chapitre 1).

7.2 Limites méthodologiques

Trois limites, déjà évoquées ponctuellement dans les chapitres précédents, méritent d’être rassemblées et hiérarchisées ici.

! 1 — Taille de l’échantillon

Avec 9 dossiers (7 labellisés pour la détection de défaut), toute métrique de performance statistique doit être interprétée comme indicative. Le LOOCV, bien qu’étant le protocole le plus rigoureux disponible à cette échelle, ne peut se substituer à une validation sur un échantillon de taille suffisante pour estimer une performance généralisable.

! 2 — Variable cible proxy

En l'absence d'historique réel d'incidents de paiement, la cible de défaut a été construite par une coupure statistique (K-means) sur le score MNS2 existant. Cette approche introduit une circularité partielle : le modèle apprend, dans une certaine mesure, à retrouver une structure déjà présente dans le score qu'il est censé compléter, plutôt qu'à prédire un événement de défaut indépendant.

! 3 — Paramètres non calibrés

Les pondérations de la grille experte (Chapitre 4) et les seuils de décision (60 %/25 %, Chapitre 6) sont des hypothèses de travail raisonnées mais non calibrées sur des données de validation indépendantes, faute d'échantillon suffisant pour réserver un sous-ensemble à cet effet.

7.3 Recommandations pour une industrialisation

Trois recommandations découlent directement des limites identifiées :

- **Constitution d'un échantillon élargi** : le workflow applicatif (Chapitre 6, Section 6.4) a été conçu pour capitaliser sur les nouveaux dossiers traités par les analystes. Chaque dossier supplémentaire, une fois validé par la Direction, peut enrichir l'échantillon d'entraînement et permettre, à terme, un passage d'une validation LOOCV à une validation train/test classique, plus robuste ;
- **Remplacement de la cible proxy** : dès qu'un historique réel d'incidents de paiement devient accessible (même partiellement), il devrait se substituer à la coupure K-means actuelle pour fonder l'apprentissage sur un événement de défaut réel plutôt que sur une structure interne au score existant ;
- **Calibration collaborative de la grille experte** : une fois un échantillon plus large disponible, les pondérations pourraient être ajustées de façon supervisée (par exemple, par une régression contrainte visant à minimiser l'écart entre score expert et notation MNS2 réelle), tout en conservant l'intelligibilité de la grille.

7.4 Conclusion générale

Ce projet répond à la problématique posée au Chapitre 1 — reconstruire et expliquer une notation bancaire perçue comme une boîte noire — par un système qui articule explicitement trois niveaux : une logique de règles transparentes (grille experte), une logique statistique (apprentissage automatique et importance des variables), et une couche de décision qui assume ses limites en renvoyant les cas incertains à l'arbitrage humain plutôt que de forcer un verdict. Les résultats obtenus, bien que devant être lus avec la prudence qu'impose la taille de l'échantillon, démontrent la faisabilité méthodologique de la démarche et fournissent une base concrète — code, base de données anonymisée, application fonctionnelle — sur laquelle une montée en échelle pourra s'appuyer.